

Институт ИТКН

Кафедра инженерной кибернетики

Направление подготовки: 01.03.04 прикладная математика

Квалификация (степень): бакалавр

Группа: **БПМ-22-ФИН-1**

ОТЧЕТ


ПО НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

на тему: «Персонализированная система рекомендаций по питанию с использованием векторной базы данных и RAG-архитектуры»

7-й семестр

2025 ÷ 2026 уч. год.

Студент



/ _____ Бабынина И.И. _____ /

подпись

Фамилия И.О.

Руководитель НИР



/доц., к.т.н. Кожаринов А.С./

подпись

должность, уч. степ. Фамилия И.О.

Оценка: _____

Дата защиты: _____

Утвердил:

Председатель комиссии

_____ / _____ /

подпись

Фамилия И.О.

Москва 2025

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	2
1. АНАЛИТИЧЕСКИЙ ОБЗОР ЛИТЕРАТУРЫ	3
1.2 Векторные базы данных	9
1.3 Методы машинного обучения в рекомендательных системах	12
1.4 Основа теории правильного питания и составления рациона.....	17
1.5 Языковые модели и объяснения рекомендаций:	20
1.6 Применение векторных баз данных в рекомендательных системах	22
2. ОСНОВНАЯ ЧАСТЬ	25
2.1 Содержательная постановка задачи.....	25
2.1.1. Алгоритмы поиска (с формализацией).....	26
2.1.2. Генерация рекомендаций: составление списка на основе введённых данных и расчётов норм калорийности и БЖУ	29
2.2. Математическая постановка задачи	32
2.2.1. Расчёт ИМТ и норм калорийности	32
2.2.2. Поиск похожих рецептов по векторным представлениям (KNN)	33
2.2.3. Математика для фильтрации по аллергенам (алгоритмы на основе метаданных).....	34
2.2.4. Алгоритм рекомендации: модель с учётом персональных данных пользователя и векторных представлений рецептов.....	36
2.3. Исходные данные	39
2.4. Программно-алгоритмическая архитектура решения	41
ЗАКЛЮЧЕНИЕ	44

ВВЕДЕНИЕ

Проблема выбора подходящего питания становится все более актуальной в современном обществе, где мода на здоровый образ жизни и правильное питание набирает обороты и все больше людей стремятся к здоровому образу жизни. Несмотря на большое количество доступных сервисов по подбору диет, большинство из них предлагают только общие рекомендации, не учитывая индивидуальные особенности пользователей. Такие системы не всегда могут учесть такие важные параметры, как цели (похудение, набор массы), антропометрические данные (вес, рост), пищевые ограничения (аллергии) и предпочтения. Это создает потребность в более персонализированных подходах, которые могут предоставить пользователю рекомендации, максимально соответствующие его запросам.

Персонализированные системы рекомендаций имеют потенциал для улучшения качества жизни, предлагая более точные и индивидуальные рекомендации по питанию. В условиях огромного объема доступных данных, таких как рецепты, состав продуктов и предпочтения пользователей, важно использовать новые технологии для эффективной обработки и анализа этих данных. Системы, учитывающие все ключевые аспекты здоровья и питания, могут помочь пользователям сделать более осознанный выбор и достичь своих целей.

Данная работа направлена на разработку системы рекомендаций по питанию, которая будет учитывать все индивидуальные данные пользователя. Она позволит не только предложить подходящие рецепты, но и дать объяснение, почему те или иные блюда наиболее соответствуют целям пользователя. Такая система способна значительно повысить удобство и эффективность использования рекомендаций, улучшая качество жизни и способствуя правильному выбору питания для каждого человека.

1. АНАЛИТИЧЕСКИЙ ОБЗОР ЛИТЕРАТУРЫ

1.1 Исследование зарубежных и российских аналогов

Как на иностранном, так и российском рынке существует несколько разработок, предоставляющих рекомендации по питанию и здоровому образу жизни с использованием технологий искусственного интеллекта и машинного обучения. В данном разделе приводится анализ существующих решений с разбором их плюсов и минусов, а также выделяются преимущества разрабатываемого программного комплекса по сравнению с ними.

1.3.1 Иностранные разработки

Lifesum - это мобильное приложение, предназначенное для отслеживания питания, контроля калорий и поддержания здорового образа жизни. Оно предоставляет пользователям возможность создавать персонализированные планы питания, учитывающие их цели, такие как похудение, поддержание веса или набор массы. Lifesum предлагает различные диетические подходы, включая диеты для вегетарианцев, людей с непереносимостью глютена и другие специализированные планы питания.

Плюсы:

- Персонализированные планы питания, учитывающие цели пользователя, такие как снижение веса или улучшение здоровья;
- База данных продуктов с возможностью сканирования штрих-кодов для быстрого ввода информации о питании;
- Разнообразие диетических подходов, включая низкоуглеводные, вегетарианские и безглютеновые диеты;
- Интуитивно понятный интерфейс и доступные рекомендации по еде и физической активности;
- Интеграция с фитнес-трекерами и другими приложениями для отслеживания физической активности.

Минусы:

- Приложение не предоставляет глубоких рекомендаций по составлению меню, учитывающих аллергии или специфические медицинские состояния пользователя;
- Бесплатная версия ограничена в функционале (только сканнер штрих-кодов и дневник калорий доступны в бесплатной версии), а для доступа к ключевым возможностям (рекомендации по питанию и занятиям спортом) требуется платная подписка (990 рублей в месяц, что выше, чем у других аналогичных приложений);
- Нет достаточно подробных объяснений, почему определенные продукты или блюда рекомендуются пользователю, что ограничивает прозрачность системы;
- Недоступно в РФ.




Рис. 1 - приветственная страница приложения Lifesum

MyFitnessPal - одно из самых популярных приложений для отслеживания питания и физической активности. Оно предоставляет пользователю возможность вести дневник питания, отслеживать калории и состав макро- и микроэлементов. Приложение также предлагает разнообразные рекомендации по питанию, основанные на целях пользователя, таких как похудение или поддержание веса.

Плюсы:

- Большая база данных продуктов (более 14 млн блюд, для каждого указано КБЖУ);
- Расчет нормы калорий по антропометрическим данным пользователя;
- Формат “социальной сети” - пользователи могут делиться фотографиями своих блюд и успехами, подписываться друг на друга и оставлять комментарии;
- Возможность отслеживания потребляемых калорий и макроэлементов;
- Интеграция с фитнес-трекерами и приложениями для здоровья.

Минусы:

- Недоступно в РФ;
- Нет персонализированных рекомендаций по составлению меню с учетом аллергий и других индивидуальных особенностей;
- Ограниченные возможности объяснения рекомендаций (пользователь не всегда понимает, почему ему предлагается тот или иной продукт и почему выбранный рацион подходит для достижения целей пользователя).




Рис. 2 - приветственная страница приложения MyFitnessPal

Yazio - мобильное приложение для отслеживания питания и составления диетических планов. Пользователи могут установить свои цели (похудение,

набор массы) и отслеживать калории и макроэлементы. В отличие от MyFitnessPal, Yazio предлагает более индивидуализированные планы питания.

Плюсы:

- Доступно в РФ;
- Простота в использовании;
- Предоставление персонализированных диетических планов;
- Множество рецептов и инструкций по приготовлению пищи.

Минусы:

- Отсутствие поиска рецептов, который учитывает не только калорийность, но и другие параметры, такие как аллергены.




Рис. 3 - приветственная страница приложения Yazio

FatSecret - популярное приложение для отслеживания питания и физической активности, которое помогает пользователям контролировать их рацион, вести дневник питания и следить за прогрессом в достижении своих целей (похудение, поддержание веса и т.д.). Приложение предоставляет пользователям доступ к базе данных продуктов питания и рецептов, а также позволяет сканировать штрих-коды продуктов для упрощения ввода информации о питании.

Плюсы:

- Обширная база данных продуктов и блюд, включая возможность сканирования штрих-кодов для быстрого добавления пищи;
- Возможность ведения дневника питания и отслеживания калорий, макро- и микроэлементов;
- Интеграция с фитнес-трекерами и другими приложениями для анализа физической активности;
- Сообщество пользователей и возможность обмена опытом и рекомендациями.

Минусы:

- Недостаточная персонализация рекомендаций на основе физических данных, таких как возраст, пол, уровень активности;
- Отсутствие гибкой системы фильтрации рецептов по индивидуальным потребностям, например, аллергиям;
- Нет полноценного объяснения, почему предлагаются те или иные продукты или рецепты для конкретного пользователя.




Рис. 4 - приветственная страница приложения FatSecret

1.3.2 Отечественные разработки

FitStars — российское приложение для тренировок и здорового питания, предлагающее пользователям разнообразные видео-тренировки и рекомендации

по диетам. Однако в этом сервисе нет персонализированных рекомендаций по питанию, и все планы питания носят общие характеристики.

Плюсы:

- Бесплатный доступ к тренировкам и рекомендациям;
- Визуализация упражнений и планы по здоровому питанию.

Минусы:

- Отсутствие персонализированных диет и рекомендаций по питанию с учетом индивидуальных данных пользователя;
- Приложение ограничено только основными категориями тренировок, не предлагая комплексных рекомендаций по питанию для конкретных целей.




Рис. 5 - приветственная страница приложения FitStars

Анализ зарубежных и российских приложений для отслеживания питания и составления диетических планов показывает, что, несмотря на большое количество доступных решений, большинство из них не обеспечивают должной персонализации рекомендаций, особенно в отношении учета аллергий, предпочтений и индивидуальных целей пользователя. Приложения, такие как Lifesum, MyFitnessPal и FatSecret, предлагают широкие базы данных продуктов и рецептов, однако их возможности по адаптации рекомендаций под специфические потребности пользователя остаются ограниченными. В то время

как Yazio и FatSecret предлагают простоту использования и возможность сканирования штрих-кодов, ни одно из этих приложений не интегрирует полноценную систему рекомендаций по питанию, учитывающую все аспекты здоровья, включая аллергии и другие важные ограничения.

Отечественные разработки, такие как FitStars, также имеют свои ограничения, включая отсутствие персонализированных диет и рекомендаций по питанию, что снижает их эффективность в решении задач, связанных с индивидуальными потребностями пользователей.

Таким образом, несмотря на наличие широкого спектра существующих решений, большинство из них не полностью удовлетворяет потребности пользователей в персонализированных рекомендациях по питанию. Разрабатываемая система имеет явные преимущества, предоставляя рекомендации, которые будут учитывать все индивидуальные параметры пользователя, такие как цели, аллергии и предпочтения, что делает ее более гибкой и полезной по сравнению с существующими аналогами.

1.2 Векторные базы данных

Векторные базы данных (VDB) — это специализированные системы управления данными, предназначенные для хранения, индексирования и эффективного поиска многомерных векторных представлений данных. Эти системы решают задачу работы с высокоразмерными данными и обеспечивают поиск по семантическому сходству объектов, что делает их незаменимыми в таких областях, как машинное обучение, рекомендательные системы и обработка больших данных.

Основной принцип работы векторных баз данных заключается в том, что данные преобразуются в векторные представления. Каждый объект, будь то текст, изображение или аудио, представляется в виде числового вектора,

который кодирует его характеристики в многомерном пространстве. Например, текстовые данные могут быть преобразованы с использованием таких методов, как TF-IDF, word2vec, или BERT, создавая векторы, которые отражают смысл слов и их взаимосвязи.

Векторные базы данных позволяют выполнять поиск на основе семантического сходства векторов, что существенно отличается от традиционного поиска по точному совпадению. Системы поиска могут использовать различные метрики расстояния, такие как косинусное расстояние или евклидова метрика, для оценки близости между векторами, что позволяет находить похожие объекты, даже если они не идентичны по тексту или атрибутам.

Поиск в векторных базах данных осуществляется с использованием алгоритмов приближенного поиска ближайших соседей (ANN). Этот метод позволяет существенно ускорить обработку запросов, сокращая вычислительные затраты за счет организации данных в кластеры. Например, при запросе "котенок" система сначала находит кластер, содержащий все объекты, связанные с четвероногими животными, а затем вычисляет расстояния только внутри этого кластера, избегая ненужного анализа всех данных.

Технологии, такие как HNSW (Hierarchical Navigable Small World) и IVF-PQ (Inverted File with Product Quantization), используются для индексации векторов. Эти методы позволяют эффективно обрабатывать миллиарды векторов с минимальной задержкой, что критично для использования в реальном времени.

Векторные базы данных нашли широкое применение в рекомендательных системах. Примером является Spotify, где векторные представления используются для персонализированных рекомендаций музыки. Система анализирует данные о предпочтениях пользователей, а также применяет алгоритмы обработки естественного языка (NLP) и аудиоанализ для создания векторных представлений треков, которые затем используются для предсказания

предпочтений пользователя. Векторные базы данных позволяют оперативно обрабатывать запросы и находить похожие треки на основе их акустических характеристик или текстовых метаданных.

Традиционные реляционные базы данных (SQL), такие как PostgreSQL или MySQL, не предназначены для работы с векторными данными и не могут эффективно обрабатывать запросы на семантическое сходство. Они ориентированы на структурированные данные и требуют точного совпадения по ключевым атрибутам, что приводит к значительным задержкам при выполнении операций с векторами. Например, при поиске схожих векторов традиционные СУБД вынуждены выполнять полное сканирование таблиц, что приводит к экспоненциальному росту времени выполнения запросов.

В отличие от реляционных СУБД, векторные базы данных оптимизированы для работы с многомерными векторами и поддерживают гибридные запросы, которые сочетают векторный поиск с фильтрацией по атрибутам, таким как цена или категория. Это позволяет рекомендательным системам эффективно работать с неструктурированными данными и обеспечивать высокую скорость обработки запросов, даже при работе с миллиардами векторов.

Сейчас существует множество современных платформ, которые используют векторные базы данных для обработки данных в рекомендательных системах. К примеру, Milvus, Qdrant и Pinecone предлагают решения для хранения и обработки миллиардов векторов с минимальной задержкой. Эти платформы оптимизированы для выполнения запросов на семантическое сходство в реальном времени и могут масштабироваться для работы с большими объемами данных.

Применение векторных баз данных в таких сервисах, как Spotify и Netflix, позволяет значительно улучшить качество рекомендаций. Эти сервисы используют сложные алгоритмы для создания векторных представлений данных

и их обработки, что позволяет обеспечить высокую точность и актуальность рекомендаций. Векторные базы данных, такие как Qdrant и Milvus, становятся неотъемлемой частью архитектуры рекомендательных систем, решая задачи хранения, индексирования и быстрого поиска векторов.

1.3 Методы машинного обучения в рекомендательных системах

В рекомендательных системах широко применяются различные методы машинного обучения (ML), которые помогают анализировать предпочтения пользователей и генерировать персонализированные рекомендации. Методы можно условно разделить на несколько типов в зависимости от их подхода к обучению и обработке данных. Рассмотрим более подробно эти методы.

Неперсонализированные системы, известные как Summary-based, оперируют агрегированными статистическими закономерностями. Их классическим воплощением служит ранжирование объектов по среднему рейтингу, как реализовано на платформе TripAdvisor. Эти системы сталкиваются с проблемой холодного старта для новых объектов. Для контента с ограниченным сроком актуальности, такого как новости или посты в социальных сетях, применяются временные корректировки, учитывающие "свежесть" материала.

1. Контентно-ориентированные системы

Контентно-ориентированные системы используют семантические характеристики объектов для построения профиля интересов пользователя. Данный подход особенно эффективен для товаров с описаниями: фильмов, книг, статей. Технической основой служит модель векторного пространства, где текстовые описания преобразуются через взвешивание TF-IDF, назначающее больший вес редким и информативным терминам. Мера близости между вектором интересов пользователя и вектором объекта вычисляется через

косинусное расстояние. Профиль пользователя динамически обновляется, причем новым взаимодействиям присваивается повышенный вес для отражения возможной эволюции предпочтений.

Плюсы:

- Легко адаптируются к индивидуальным предпочтениям пользователя;
- Не требуют данных о других пользователях, а только о характеристиках объекта.

Минусы:

- Рекомендации могут быть ограничены, если пользователь не взаимодействует с разнообразными объектами;
- Не учитывают скрытые предпочтения, которые могут выявляться через взаимодействие с другими пользователями.

2. Системы коллаборативной фильтрации

Основная идея этого типа систем заключается в сопоставлении пользователей и товаров (или услуг, новостей и т. д.). Этот метод использует матрицы предпочтений, в которых лежат пользовательские оценки товаров, а также вычисляет матрицы сходства между всеми пользователями или объектами, в зависимости от выбранного подхода.

	Товар 1	Товар 2	Товар 3	Товар 4	Товар 5
Клиент 1		3		5	
Клиент 2	1		1	1	
Клиент 3	2			3	2
Клиент 4		4			5
Клиент 5	5		2	3	4

Рис.6 Матрица предпочтений

В качестве меры схожести, как правило, используют два основных подхода в совместной фильтрации: основанный на пользователях и основанный на предметах рекомендации.

- Коллаборативные системы, основанные на пользователях (user-based), находят пользователей со схожими предпочтениями и рекомендуют одному из них те предметы, которые другой уже попробовал и оценил. Это наиболее часто используемый подход, при котором матрица сходства вычисляется для каждого пользователя. Основным недостатком этого подхода заключается в значительных вычислительных затратах, необходимых для построения этой матрицы, поскольку число пользователей обычно очень велико, а количество рейтингов – нет, что приводит к разреженной матрице.
- Системы, основанные на предмете рекомендации (item-based), работают точно также, но определяют сходство непосредственно между объектами, учитывая рейтинг от пользователей. Основным преимуществом данного подхода, помимо его меньшей требовательности к вычислительным ресурсам (поскольку, как правило, количество товаров 12 значительно меньше количества пользователей), является то, что оценки объекта не изменяются так же быстро, как пользовательские оценки.

Плюсы:

- Эффективен при большом объеме данных и многочисленных пользователях;
- Простой в реализации и применении для различных типов данных (фильмы, товары и т. д.).

Минусы:

- Проблема холодного старта: для новых объектов или пользователей система не может эффективно делать рекомендации;

- Высокие вычислительные затраты при большом количестве пользователей и объектов.

3. Гибридные системы

Последний тип рекомендательных систем – это гибридный. Такая система сочетает в себе два предыдущих типа, которые основаны на предпочтениях пользователей и характеристиках товаров. Ни один из базовых подходов не способен в полной мере реализовать это. Следовательно, создание гибридных систем, совмещающих в себе преимущества различных алгоритмов и моделей, для преодоления вышеупомянутых недостатков и проблем, стало целью недавних исследований. Netflix, крупнейшая компания по аренде DVD, даже проводила открытое соревнование на лучший алгоритм предсказания оценки, которую зритель поставит фильму, на основе предыдущих оценок этого и других зрителей в 2006 году.

Гибридные системы могут быть:

- Смешанными: где результаты от разных подходов комбинируются на последнем этапе (например, рейтинг комбинируется с характеристиками объектов);
- Интегрированными: где различные модели обучаются и работают вместе, например, в контентной фильтрации и коллаборативной фильтрации.

Плюсы:

- Способны улучшить точность рекомендаций, сочетая преимущества различных подходов;
- Могут уменьшить проблему холодного старта, комбинируя контентный и поведенческий подходы.

Минусы:

- Сложность реализации и интеграции различных методов;
- Высокие вычислительные затраты, требующие мощных вычислительных ресурсов.

Методы машинного обучения в рекомендательных системах позволяют значительно улучшить точность и релевантность рекомендаций. В зависимости от используемых данных и целей, могут применяться различные алгоритмы. Например, SVD (Singular Value Decomposition) используется для матричной факторизации в коллаборативной фильтрации, а CNN (Convolutional Neural Networks) и RNN — для обработки изображений и текста.

Гибридные рекомендательные системы комбинируют различные методы и алгоритмы, чтобы преодолеть недостатки каждого из них, улучшая точность и полноту рекомендаций. В гибридных системах можно сочетать подходы на основе коллаборативной фильтрации, контентной фильтрации и других методов, включая использование машинного обучения для более точной персонализации.

1. Модели на основе матричной факторизации

Матричная факторизация является одним из ключевых методов в коллаборативной фильтрации, особенно в контексте гибридных систем. Она помогает решать проблему разреженности данных (когда не все пользователи оценивают все объекты).

- Singular Value Decomposition (SVD)

Метод факторизации матрицы, используемый для анализа предпочтений пользователей и объектов. В гибридных системах SVD может быть использован для создания скрытых факторов, которые затем комбинируются с контентной информацией о товарах или фильмах для улучшения рекомендаций.

- Alternating Least Squares (ALS)

Этот метод оптимизации используется для минимизации ошибки в предсказаниях, что помогает улучшить точность коллаборативной фильтрации. В гибридной системе ALS может быть использован в сочетании с контентной фильтрацией, где сначала создается факторизация матрицы предпочтений, а затем она комбинируется с атрибутами объектов для создания более точных рекомендаций.

2. Использование ансамблевых методов

В гибридных системах часто используются ансамбли моделей, которые объединяют результаты нескольких различных алгоритмов для получения более точных и стабильных рекомендаций.

- Бустинг и бэггинг: Методы бустинга (например, XGBoost) и бэггинга могут быть использованы для комбинирования предсказаний, полученных от различных моделей (например, коллаборативной фильтрации и контентной фильтрации). Эти методы помогают уменьшить переобучение и повысить точность рекомендаций.
- Stacking: В методах stacking несколько различных моделей (например, нейронные сети, SVD, коллаборативная фильтрация) комбинируются с использованием дополнительной мета-модели, которая обрабатывает их выводы для получения окончательной рекомендации.

1.4 Основа теории правильного питания и составления рациона

Правильный расчёт базового обмена веществ (БОВ), суточной калорийности и БЖУ критически важны для спортивных результатов, будь то похудение, набор массы или поддержание формы.

Базовый обмен веществ (БОВ) – показывает, сколько калорий тратит тело в покое

Если потреблять меньше необходимого количества калорий по формуле базового обмена веществ – организм переходит в режим энергосбережения, замедляется метаболизм и сжигаются мышцы. Если же наоборот потреблять намного больше калорий без тренировок – растёт жир.

Суточная калорийность с учётом активности (TDEE) – определяет, сколько калорий нужно для поставленной цели тренировок, будь то похудение, набор массы или поддержание формы. При недостатке калорий нет энергии на физическую активность, идёт разрушение мышц. Избыток калорий без достаточной нагрузки приводит к дополнительному жиरोотложению.

Баланс БЖУ – «топливо и строительный материал» для организма человека, поскольку каждый компонент имеет свою функцию:

- белок защищает мышцы при похудении, и обеспечивает прирост сухой мышечной ткани;
- жиры регулируют гормоны и играют важную роль в усвоении витаминов;
- углеводы дают энергию для тренировок и особенно важны при наборе массы.

При игнорировании баланса БЖУ возможные следующие последствия :

- при недостатке белка происходит процесс разрушения мышц даже при тренировках;
- при нехватке жиров происходит падение тестостерона, ухудшение восстановления;
- при избытке/недостатке углеводов наблюдается вялость или скапливается лишний жир.

Формула расчета базового обмена веществ (БОВ) в основном представляется формулой Харриса-Бенедикта (1-2).

Для мужчин:

$$BMR = 88.362 + 13.397 \cdot X + 4.799 \cdot Y - 5.677 \cdot Z, \quad (1)$$

Для женщин:

$$BMR = 447.593 + 9.24 \cdot X + 3.09 \cdot Y - 4.330 \cdot Z, \quad (2)$$

где X – вес в килограммах, Y – рост в сантиметрах, Z – возраст в годах.

Формула (3) расчета суточной калорийности с учетом уровня активности (TDEE):

$$TDEE = BOB * \text{уровень активности}, \quad (3)$$

где уровень активности может быть классифицирован по следующей шкале:

- 1.2 (сидячий образ жизни);
- 1.375 (легкие физические нагрузки);
- 1.55 (умеренные физические нагрузки);
- 1.725 (активные физические нагрузки);
- 1.9 (очень активные физические нагрузки).

Рекомендация по макроэлементам содержит следующее стандартное распределение калорий между белками, жирами и углеводами:

- для похудения: 40% углеводов, 30% белков, 30% жиров;
- для набора мышечной массы: 50% углеводов, 25% белков, 25% жиров.

Для спортсменов рекомендуется потребление белка в диапазоне от 1.6 до 2.2 граммов на килограмм массы тела в зависимости от целей (набор мышечной массы, поддержание или похудение). Для добавок (например, креатин) можно использовать рекомендации на основе веса и интенсивности тренировок.

1.5 Языковые модели и объяснения рекомендаций:

С развитием технологий искусственного интеллекта и машинного обучения, особенно в области обработки естественного языка (NLP), языковые модели стали важным инструментом для улучшения персонализации и объяснения рекомендаций. Языковые модели, такие как GPT (Generative Pretrained Transformer), способны генерировать текст на основе входных данных, что делает их полезными для создания объяснений к рекомендациям, генерируемым рекомендательными системами.

Языковые модели используются в рекомендательных системах для того, чтобы не просто предсказывать, какие объекты или продукты могут заинтересовать пользователя, но и предоставить подробные объяснения того, почему был сделан тот или иной выбор. Объяснение рекомендаций является важным элементом для повышения доверия пользователя к системе и улучшения его опыта.

Применение языковых моделей позволяет ответить на вопросы пользователей, такие как: «Почему мне рекомендован этот фильм?» или «Как этот рецепт соответствует моим целям по питанию?». Это особенно важно в случаях, когда рекомендации могут включать неоднозначные или непривычные объекты для пользователя. Объяснения могут быть полезными для того, чтобы убедить пользователя в правильности предложенного выбора и дать ему понимание, как его личные данные и предпочтения повлияли на результат.

В рекомендательных системах можно выделить несколько подходов к использованию языковых моделей для объяснений:

- Генерация текстовых объяснений: Языковые модели, такие как GPT или T5, могут генерировать текст, объясняющий, почему тот или иной объект был рекомендован. Эти объяснения могут включать информацию о предпочтениях пользователя (например, «Этот фильм был рекомендован

вам, потому что вы любите драмы с элементами фантастики») или основаны на других данных, таких как характеристики объекта (например, «Этот рецепт рекомендован вам, так как в нем используется больше белков, что соответствует вашей цели по набору массы»).

- Использование атрибуции: Языковые модели могут быть использованы для атрибуции, т.е. объяснения, какие именно характеристики объекта (например, жанр фильма или состав ингредиентов блюда) стали причиной рекомендации. Такие методы часто используются для более прозрачных объяснений, где пользователь может понять, какие именно аспекты данных повлияли на результат.
- Интерпретация рекомендаций на основе контекста: В некоторых случаях важно учитывать контекст взаимодействия пользователя с системой. Например, если рекомендация делается в контексте времени дня или текущего состояния пользователя (например, усталость или стресс), языковая модель может учитывать эти факторы и генерировать объяснение, которое более точно отражает реальное поведение системы.

Современные языковые модели, такие как GPT-4 и T5, основываются на архитектуре Transformer, которая позволяет эффективно обрабатывать большие объемы данных и генерировать высококачественные текстовые объяснения. Эти модели обучаются на больших текстовых корпусах и способны понимать контекст, что делает их мощными инструментами для создания персонализированных объяснений.

- GPT-4 (Generative Pretrained Transformer 4): Эта модель используется для генерации текстов, создания диалогов и предоставления объяснений. GPT-4 может быть адаптирован под конкретную задачу, например, объяснение рекомендаций, путем дополнительного обучения на специфических данных, таких как предпочтения пользователя или характеристики объектов.

- T5 (Text-to-Text Transfer Transformer): Модель T5 переводит все задачи обработки языка в задачу преобразования текста в текст. Это делает ее очень гибкой, так как ее можно использовать для различных типов задач, включая генерацию объяснений и ответы на вопросы, что полезно для создания объяснений рекомендаций.
- BERT (Bidirectional Encoder Representations from Transformers): Хотя BERT преимущественно используется для задач, связанных с классификацией текста и пониманием контекста, его можно использовать в рекомендательных системах для улучшения качества обработки запросов и формирования более точных объяснений, особенно когда важна семантическая близость между объектами.

Таким образом, языковые модели представляют собой мощный инструмент для улучшения персонализации рекомендаций и предоставления пользователю ясных и доступных объяснений, что в конечном итоге ведет к улучшению взаимодействия с системой и повышению доверия пользователей.

1.6 Применение векторных баз данных в рекомендательных системах

Векторные базы данных (Vector Database, VDB) в современных рекомендательных системах используются как специализированный слой семантического поиска, позволяющий извлекать объекты не по точному совпадению ключевых слов, а по близости смыслового представления. Данный подход особенно релевантен для задач, где объекты имеют выраженную «семантическую природу» — например, рецепты, включающие текстовые описания, перечни ингредиентов, кулинарные инструкции и дополнительные атрибуты (калорийность, БЖУ, тип кухни, теги и т. п.). В отличие от традиционного поиска, основанного на явных критериях, семантический поиск опирается на вычисление сходства векторов по метрикам расстояния (в частности, косинусной мере), что принципиально расширяет возможности подбора релевантного контента по смыслу пользовательского запроса.

При построении рекомендательной подсистемы рецепты представляются в виде эмбедингов — числовых векторов, кодирующих семантику объекта; близость векторов в многомерном пространстве интерпретируется как близость по смыслу. На практике это позволяет выполнять запросы вида «высокобелковый ужин для набора массы» и получать рецепты, наиболее близкие к данному намерению, даже если точные слова запроса отсутствуют в тексте рецепта. Технически такой поиск реализуется через задачу поиска ближайших соседей: для вектора запроса необходимо найти набор векторов рецептов, расположенных ближе всего согласно выбранной метрике сходства.

Наиболее распространённая метрика в подобных сценариях — косинусное сходство, измеряющее угол между векторами и тем самым фокусирующееся на направлении (семантике), а не на модуле вектора. Косинусная мера хорошо работает для текстовых эмбедингов и смешанных представлений, где важна сопоставимость «смысловых направлений», а не абсолютных значений признаков; именно поэтому векторные системы прямо опираются на вычисление сходства через такие метрики. Для практической реализации рекомендации обычно используются процедуры KNN (k-nearest neighbors): система возвращает k ближайших рецептов к вектору запроса или к вектору «профиля пользователя» (агрегированного представления его целей и предпочтений). В прикладном смысле KNN в задачах рецептов интерпретируется как «выдать топ- k наиболее похожих блюд», после чего результаты могут быть дополнительно ранжированы или отфильтрованы.

Ключевая проблема прямого KNN в больших коллекциях — вычислительная сложность полного перебора. Поэтому векторные БД используют приближённый поиск ближайших соседей (ANN): векторы предварительно организуются (например, кластеризуются), и поиск выполняется не по всему множеству, а внутри релевантной области пространства, что снижает вычислительную нагрузку и обеспечивает отклик на уровне миллисекунд даже на очень больших массивах данных. Важным следствием является возможность

применять семантический поиск в интерактивных пользовательских приложениях, где задержка ответа непосредственно влияет на удобство системы рекомендаций.

С инженерной точки зрения использование VDB в рекомендательных системах обычно оформляется как конвейер из трёх этапов: (1) индексация эмбедингов в оптимизированные структуры, (2) выполнение запроса путём сравнения вектора запроса с индексированными данными по метрике сходства, (3) постобработка результатов (ранжирование, фильтрация, объединение с исходным контентом). Для индексации применяются специализированные алгоритмы (например, HNSW для графового поиска и IVF для сжатия/организации данных), обеспечивающие баланс точности и производительности. Для предметной области питания это означает, что семантический кандидатный набор рецептов можно получать быстро, а затем уже «дожимать» качество рекомендаций строго логическими правилами.

Практически значимое преимущество векторных БД для рекомендаций по питанию связано с поддержкой **гибридных запросов**: семантический поиск по эмбедингам сочетается с фильтрацией по метаданным. Для рецептов это критично, поскольку часть условий должна выполняться строго: исключение аллергенов, соответствие медицинским ограничениям, допустимые диапазоны калорийности или БЖУ. Таким образом, типовой сценарий рекомендаций формулируется как: «найти семантически релевантные рецепты» + «отфильтровать по ограничениям» + «отранжировать по соответствию цели». В итоговой архитектуре это позволяет разделить ответственность: VDB отвечает за быстрый смысловой поиск похожих рецептов, а атрибутивная фильтрация и доменные правила обеспечивают корректность и безопасность выдачи.

2. ОСНОВНАЯ ЧАСТЬ

2.1 Содержательная постановка задачи

В рамках данной работы рассматривается задача построения персонализированной системы рекомендаций по питанию, предназначенной для подбора рецептов и формирования рациональных предложений на основе индивидуальных характеристик пользователя. Под персонализацией в данном контексте понимается адаптация рекомендаций под конкретного человека с учётом его антропометрических данных (масса тела, рост, возраст, пол), цели питания (снижение массы тела, набор мышечной массы, поддержание текущей формы), а также индивидуальных ограничений и предпочтений (аллергии, исключаемые продукты, предпочтительный тип кухни и т. п.).

Входными данными системы являются параметры пользователя, вводимые через интерфейс: антропометрия, уровень физической активности, целевая направленность рациона, перечень аллергенов и (при наличии) предпочтения по типам блюд. На основании этих данных система выполняет первичную оценку энергетических потребностей пользователя (суточная калорийность) и целевых ориентиров по распределению макроэлементов (белки, жиры, углеводы), соответствующих выбранной цели. Эти расчёты формируют базовые ограничения и критерии качества рекомендации: рецепты должны быть релевантны цели пользователя по энергетической ценности и макронутриентному составу, а также не содержать запрещённых ингредиентов.

Объектами рекомендаций выступают рецепты из заранее подготовленного набора данных, содержащего текстовое описание, список ингредиентов и метаданные (калорийность, БЖУ, категории, потенциальные аллергены). Для формирования кандидатов используется поиск по семантическому сходству, позволяющий учитывать не только точные совпадения по ключевым словам, но и смысловую близость запроса пользователя (например, «белковый ужин для набора массы», «низкокалорийный перекус»). После извлечения кандидатов

система применяет детерминированные фильтры по аллергенам и ограничениям, исключая рецепты, потенциально опасные или не соответствующие заданным условиям.

Результатом работы системы является ранжированный список рекомендованных рецептов, сопровождаемый краткой интерпретацией причин выбора. Объяснения предназначены для повышения прозрачности рекомендаций и повышения доверия пользователя к системе: они должны связывать параметры пользователя (цель, ограничения, рассчитанные нормы) с характеристиками предложенного блюда (калорийность, БЖУ, ингредиентный состав). Таким образом, содержательная постановка задачи включает разработку логики персонализации, механизмов семантического поиска, строгих фильтров по ограничениям и формата представления рекомендаций в виде, удобном для практического использования.

2.1.1. Алгоритмы поиска (с формализацией)

Алгоритм поиска в разрабатываемой системе рекомендаций по питанию строится как композиция двух процедур: (1) семантического извлечения кандидатов по векторным представлениям рецептов и (2) строгой фильтрации по ограничениям пользователя (аллергены, запрещённые ингредиенты и иные правила). Такой подход позволяет совместить «мягкую» релевантность по смыслу с «жёсткой» корректностью по медицинским и диетологическим ограничениям.

1) Семантический поиск по векторным представлениям

Пусть имеется множество рецептов $D = \{r_1, \dots, r_N\}$. Каждому рецепту сопоставляется эмбединг

$$x_i = f(r_i) \in R^d, \quad (4)$$

где $f(\cdot)$ — функция векторизации (эмбединговая модель), d — размерность векторного пространства. Пользовательский запрос (или намерение) также переводится в вектор

$$q = g(u) \in R^d, \quad (5)$$

где $g(\cdot)$ — функция формирования вектора запроса на основе данных пользователя u (например, цель, предпочтения, текстовое описание «высокобелковый ужин»).

Для оценки близости рецепта к запросу используется косинусное сходство:

$$\text{sim}_{\cos}(q, x_i) = \frac{q \cdot x_i}{\|q\| \|x_i\|}. \quad (6)$$

Эквивалентно можно задавать расстояние

$$d_{\cos}(q, x_i) = 1 - \text{sim}_{\cos}(q, x_i). \quad (7)$$

Задача извлечения кандидатов формулируется как поиск множества K ближайших соседей:

$$C_K(q) = \text{Top}K_{r_i \in D} \text{sim}_{\cos}(q, x_i), \quad (8)$$

то есть выбираются рецепты с максимальным значением сходства. На практике векторная база данных реализует приближённый поиск ближайших соседей (ANN), что снижает вычислительную сложность по сравнению с полным перебором $O(N)$ и позволяет получать ответ в интерактивном режиме.

2) Фильтрация по аллергенам и ограничениям (строгая логика)

Пусть пользователь задаёт множество запрещённых аллергенов (или ингредиентов)

$$A_u = \{a_1, \dots, a_m\}. \quad (9)$$

Для каждого рецепта известен набор аллергенов/маркеров

$$A(r_i) \subseteq A. \quad (10)$$

Тогда правило допустимости рецепта по аллергенам задаётся как булева функция:

$$allow(r_i) = \{1, A(r_i) \cap A_u = \emptyset \mid 0, \text{ иначе} \} \quad (11)$$

Аналогично вводятся прочие ограничения (например, «без лактозы», «без сахара», «низкоуглеводный рацион») через предикаты $c_j(r_i, u) \in \{0,1\}$. Итоговая допустимость рецепта определяется конъюнкцией условий:

$$feasible(r_i, u) = allow(r_i) \cdot \prod_{j=1}^J c_j(r_i, u). \quad (12)$$

После фильтрации формируется множество допустимых кандидатов:

$$F_K(q, u) = \{r_i \in C_K(q) \mid feasible(r_i, u) = 1\}. \quad (13)$$

3) Ранжирование с учётом цели и нутриентных требований

Для персонализации рекомендуется учитывать близость нутриентных характеристик рецепта к целевым значениям пользователя. Пусть для пользователя рассчитаны целевые значения суточной калорийности и БЖУ:

$$TDEE_u, P_u, F_u, C_u, \quad (14)$$

а для рецепта известны калорийность и БЖУ порции:

$$E(r_i), P(r_i), F(r_i), C(r_i). \quad (15)$$

Определим штраф за отклонение рецепта от целевого профиля (в простейшем виде — взвешенная сумма относительных отклонений):

$$\Delta(r_i, u) = w_E \left| \frac{E(r_i) - E_u}{E_u} \right| + w_P \left| \frac{P(r_i) - P_u}{P_u} \right| + w_F \left| \frac{F(r_i) - F_u}{F_u} \right| + w_C \left| \frac{C(r_i) - C_u}{C_u} \right|, \quad (16)$$

где $w_E, w_P, w_F, w_C \geq 0$ — веса важности критериев, а E_u может быть задан как целевая калорийность приёма пищи (например, доля от $TDEE_u$).

Тогда итоговая функция ранжирования может быть задана как комбинация семантической релевантности и нутриентного соответствия:

$$S(r_i \mid q, u) = \alpha \cdot \text{sim}_{\cos}(q, x_i) - (1 - \alpha) \cdot \Delta(r_i, u), \quad \alpha \in [0,1]. \quad (17)$$

Окончательный список рекомендаций получается сортировкой допустимых кандидатов по убыванию S :

$$R(u) = \text{SortDesc}_{r_i \in FK_k(q,u)} S(r_i \mid q, u). \quad (18)$$

Таким образом, алгоритм поиска в системе формализуется как: векторизация рецептов и запроса $\rightarrow$ извлечение $Top - K$ ближайших соседей по косинусному сходству $\rightarrow$ строгая фильтрация по аллергенам и ограничениям $\rightarrow$ ранжирование с учётом соответствия целям по нутриентам и калорийности. Эта схема обеспечивает одновременно релевантность рекомендаций по смыслу и гарантированное соблюдение пользовательских ограничений.

2.1.2. Генерация рекомендаций: составление списка на основе введённых данных и расчётов норм калорийности и БЖУ

Генерация рекомендаций в разрабатываемой системе представляет собой формализованную процедуру, в рамках которой из множества рецептов формируется упорядоченный список блюд, соответствующих целям пользователя, его антропометрическим характеристикам и ограничениям по питанию. Входными данными выступают параметры пользователя u : пол, возраст, масса тела X (кг), рост Y (см), уровень физической активности, цель (снижение массы тела, набор мышечной массы или поддержание формы), а также ограничения (например, аллергены) и предпочтения по типам блюд.

Результатом работы алгоритма является множество рекомендованных рецептов $R(u)$, ранжированное по степени соответствия целевому профилю пользователя.

На первом шаге система вычисляет базовый обмен веществ (БОВ) по формуле Харриса–Бенедикта (1-2). Далее рассчитывается суточная потребность в энергии с учётом активности (TDEE):

$$TDEE = BMR \cdot A, \quad (19)$$

где A — коэффициент активности. Затем вводится целевая суточная калорийность $TDEE_u$, определяемая выбранной целью пользователя. В базовой постановке:

$$TDEE_u = \{ TDEE \cdot (1 - \delta), \text{похудение} \mid TDEE, \text{поддержание} \mid TDEE \cdot (1 + \delta), \text{набор массы}, \quad (20)$$

где $\delta \in (0,1)$ — коэффициент дефицита/профицита (задаётся системно или выбирается пользователем как уровень интенсивности).

Следующим шагом определяется целевое распределение калорий между белками, жирами и углеводами. Пусть $\alpha_p, \alpha_f, \alpha_c$ — доли калорий на белки, жиры и углеводы ($\alpha_p + \alpha_f + \alpha_c = 1$). Тогда суточные нормы в граммах вычисляются как:

$$P_u = \frac{\alpha_p \cdot TDEE_u}{4}, F_u = \frac{\alpha_f \cdot TDEE_u}{9}, C_u = \frac{\alpha_c \cdot TDEE_u}{4}, \quad (21)$$

где 4 и 9 — энергетическая ценность 1 г белков/углеводов и 1 г жиров соответственно (ккал/г).

После формирования целевого нутриентного профиля система отбирает рецепты-кандидаты из базы данных. Каждый рецепт r_i характеризуется

энергетической ценностью $E(r_i)$ и БЖУ: $P(r_i), F(r_i), C(r_i)$. Для сопоставления рецепта и целевых параметров вводится функция отклонения (штраф):

$$\Delta(r_i, u) = w_E \left| \frac{E(r_i) - E_u}{E_u} \right| + w_P \left| \frac{P(r_i) - R_u}{R_u} \right| + w_F \left| \frac{F(r_i) - F_u}{F_u} \right| + w_C \left| \frac{C(r_i) - C_u}{C_u} \right|, \quad (22)$$

где $w_E, w_P, w_F, w_C \geq 0$ — веса критериев, а E_u — целевая калорийность одного приёма пищи (например, фиксированная доля от $TDEE_u$ в зависимости от режима питания). Чем меньше $\Delta(r_i, u)$, тем выше соответствие рецепта целевому профилю пользователя.

Параллельно применяется фильтрация по ограничениям, в первую очередь по аллергенам. Пусть A_u — множество запрещённых аллергенов пользователя, а $A(r_i)$ — множество аллергенов рецепта. Тогда рецепт допускается, если:

$$A(r_i) \cap A_u = \emptyset. \quad (23)$$

Итоговый список рекомендаций формируется ранжированием допустимых рецептов по минимальному значению $\Delta(r_i, u)$ (или по комбинированному критерию, если дополнительно учитывается семантическая релевантность). Формально:

$$R(u) = \text{Top}N_{r_i \in D: A(r_i) \cap A_u = \emptyset}(-\Delta(r_i, u)), \quad (24)$$

где N — число выдаваемых рекомендаций. Таким образом, генерация рекомендаций сводится к построению целевого нутриентного профиля пользователя на основе расчёта калорийности и БЖУ и последующему отбору и ранжированию рецептов, удовлетворяющих ограничениям и наиболее близких к целевым значениям.

2.2. Математическая постановка задачи

В рамках работы формализуется задача персонализированной рекомендации рецептов на основе антропометрических характеристик пользователя, его цели питания и ограничений, а также семантической близости рецептов к запросу. Пусть пользователь задаётся набором параметров $u = (sex, X, Y, Z, A, goal, A_u)$, где sex — пол, X — масса тела (кг), Y — рост (см), Z — возраст (лет), A — коэффициент физической активности, $goal$ — целевая установка (похудение/набор массы/поддержание), A_u — множество аллергенов и запрещённых компонентов. Имеется множество рецептов $D = \{ri_i\}_{i=1}^N$, для каждого рецепта доступны его нутриентные характеристики и текстовое описание.

2.2.1. Расчёт ИМТ и норм калорийности

Для оценки антропометрического статуса пользователя используется индекс массы тела (ИМТ):

$$BMI = \frac{X}{(H)^2} \quad (25)$$

где X — масса тела (кг), H — рост в метрах.

Энергетическая потребность пользователя определяется через базовый обмен веществ (БОВ), вычисляемый по формуле Харриса–Бенедикта (1-2). Суточная калорийность с учётом активности (Total Daily Energy Expenditure, TDEE):

$$TDEE = BMR \cdot A \quad (19)$$

Далее вводится целевая суточная калорийность ($TDEE_u$), зависящая от цели пользователя. В базовой модели:

$$TDEE_u = \{ TDEE \cdot (1 - \delta), \text{похудение} \mid TDEE, \text{поддержание} \mid TDEE \cdot (1 + \delta), \text{набор массы}, \quad (20)$$

где $\delta \in (0,1)$ — коэффициент дефицита/профицита.

Пусть $\alpha_P, \alpha_F, \alpha_C$ — доли калорий, приходящиеся на белки, жиры и углеводы ($\alpha_P + \alpha_F + \alpha_C = 1$). Тогда целевые нормы макронутриентов в граммах:

$$P_u = \frac{\alpha_P \cdot TDEE_u}{4}, F_u = \frac{\alpha_F \cdot TDEE_u}{9}, C_u = \frac{\alpha_C \cdot TDEE_u}{4}, \quad (21)$$

Полученные значения $(TDEE_u, P_u, F_u, C_u)$ формируют целевой нутриентный профиль пользователя.

2.2.2. Поиск похожих рецептов по векторным представлениям (KNN)

Для реализации семантического поиска каждый рецепт r_i переводится в векторное представление (эмбединг):

$$x_i = f(r_i) \in R^d, \quad (4)$$

где $f(\cdot)$ — функция векторизации текстового описания рецепта, d — размерность пространства. Пользовательскому запросу (или формализованному намерению) сопоставляется вектор:

$$q = g(u) \in R^d, \quad (5)$$

где $g(\cdot)$ формирует представление запроса на основе цели и предпочтений пользователя (например, «высокобелковый ужин для набора массы»).

Для измерения близости используется косинусное сходство:

$$sim_{cos}(q, x_i) = \frac{q \cdot x_i}{\|q\| \|x_i\|} \quad (6)$$

Задача поиска ближайших соседей формулируется как выбор K рецептов с максимальным значением сходства:

$$C_K(q) = TopK_{r_i \in D} sim_{cos}(q, x_i), \quad (8)$$

Множество $C_K(q)$ является набором кандидатов, семантически наиболее близких к запросу пользователя. Дальнейшая обработка кандидатов (фильтрация по аллергенам и ранжирование по нутриентному соответствию) выполняется на последующих этапах алгоритма рекомендаций.

2.2.3. Математика для фильтрации по аллергенам (алгоритмы на основе метаданных)

Фильтрация по аллергенам в задаче рекомендаций по питанию относится к классу жёстких (детерминированных) ограничений: рецепт либо допустим для пользователя, либо должен быть исключён из множества кандидатов независимо от степени семантической релевантности и нутриентного соответствия. В математической постановке это оформляется через операции над множествами и булевы предикаты, вычисляемые по метаданным рецептов.

Пусть задан универсальный справочник аллергенов A (например, «молоко», «яйцо», «орехи», «рыба», «глутен» и т. д.). Для пользователя u определяется множество запрещённых аллергенов:

$$A_u \subseteq A \quad (26)$$

Для каждого рецепта r_i из множества D в базе данных хранится множество аллергенов, присутствующих в рецепте (в виде метаданных):

$$A_u \subseteq A \quad (27)$$

Тогда условие допустимости рецепта по аллергенам формулируется как отсутствие пересечения множеств:

$$A(r_i) \subseteq A \quad (10)$$

Введём булев предикат допустимости по аллергенам:

$$allow_{all}(r_i, u) = \{1, A(r_i) \cap A_u = \emptyset, | 0, \text{ иначе} \quad (11)$$

Если, помимо аллергенов, пользователь задаёт дополнительные запреты по ингредиентам (например, «не употребляю свинину», «без сахара») либо медицинские ограничения (например, «низкий гликемический индекс»), их можно формализовать аналогично. Пусть B_u — множество запрещённых ингредиентов, а $I(r_i)$ — множество ингредиентов рецепта. Тогда запрет по ингредиентам описывается условием:

$$I(r_i) \cap B_u = \emptyset \quad (30)$$

и соответствующим предикатом $allow_{ing}(r_i, u)$.

В общем виде совокупность всех диетических и медицинских ограничений описывается системой предикатов $c_j(r_j, u) \in \{0,1\}, j = 1, \dots, J$, каждый из которых проверяет одно правило. Итоговая допустимость рецепта определяется конъюнкцией ограничений:

$$feasible(r_i, u) = allow_{all}(r_i, u) \cdot \prod_{j=1}^J c_j(r_i, u). \quad (31)$$

Фильтрация применяется к множеству кандидатов, полученных на предыдущем этапе (например, после семантического поиска $C_K(q)$). Тогда множество допустимых рецептов определяется как:

$$F_K(q, u) = \{r_i \in C_K(q) \mid feasible(r_i, u) = 1\} \quad (12)$$

С вычислительной точки зрения проверка ограничений может выполняться за $O(|A(r_i)| + |A_u|)$ при реализации через хеш-множества или битовые маски. В случае использования битовых представлений для аллергенов (двоичный вектор длины $|A|$) условие отсутствия пересечения может быть проверено операцией побитового AND:

$$a(r_i) \& a(u) = 0, \quad (32)$$

где $a(r_i)$ и $a(u)$ — бинарные векторы аллергенов рецепта и пользователя соответственно.

Таким образом, фильтрация по аллергенам математически сводится к проверке пересечения множеств (или эквивалентной булевой операции), что обеспечивает строгое выполнение критических ограничений и исключает потенциально опасные рекомендации на этапе формирования итогового списка.

2.2.4. Алгоритм рекомендации: модель с учётом персональных данных пользователя и векторных представлений рецептов

Алгоритм рекомендаций в разрабатываемой системе формализуется как задача ранжирования рецептов, в которой одновременно учитываются (1) семантическая релевантность рецепта пользовательскому намерению, (2) соответствие рецепта целевым нутриентным характеристикам пользователя и (3) выполнение жёстких ограничений (аллергены и иные запреты). Пусть задан пользователь (u) и множество рецептов $D = \{r_i\}_{i=1}^N$. Для каждого рецепта известны метаданные, включающие энергетическую ценность и БЖУ, а также структурированная информация об аллергенах и ингредиентах.

1) Персональный профиль пользователя

На основе антропометрических данных и цели рассчитывается целевой профиль пользователя, включающий целевую суточную калорийность $TDEE_u$ и целевые нормы макроэлементов (P_u, F_u, C_u) , полученные согласно формулам раздела 2.2. Пусть также задана целевая калорийность одного приёма пищи E_u (например, как доля от $TDEE_u$).

2) Векторное представление рецептов и пользовательского запроса

Каждому рецепту r_i сопоставляется векторное представление (эмбединг) $x_i \in R^d$:

$$x_i = f(r_i), \tag{33}$$

где $f(\cdot)$ — функция векторизации, строящая эмбединг по текстовой составляющей рецепта (название, описание, ингредиенты, теги). Для пользователя формируется вектор запроса $q \in R^d$:

$$q = g(u), \quad (34)$$

где $g(\cdot)$ задаёт намерение пользователя (например, «низкокалорийный ужин», «высокобелковый перекус») с учётом цели питания и предпочтений.

Семантическая релевантность оценивается косинусным сходством:

$$sim_{cos}(q, x_i) = \frac{q \cdot x_i}{||q|| ||x_i||}. \quad (6)$$

3) Отбор кандидатов (KNN) и фильтрация по ограничениям

На первом шаге формируется множество кандидатов как (K) ближайших соседей к запросу:

$$C_K(q) = TopK_{r_i \in D} sim_{cos}(q, x_i). \quad (8)$$

Далее применяется жёсткая фильтрация по аллергенам. Пусть $A_u \subseteq A$ — множество аллергенов пользователя, $A(r_i) \subseteq A$ — аллергены рецепта. Тогда допустимость рецепта определяется условием:

$$A(r_i) \cap A_u = \emptyset. \quad (35)$$

Итоговое множество допустимых кандидатов:

$$F_K(q, u) = \{r_i \in C_K(q) \mid A(r_i) \cap A_u = \emptyset\}. \quad (36)$$

При наличии дополнительных ограничений (запрещённые ингредиенты, тип диеты и т. п.) они добавляются как дополнительные предикаты допустимости, формируя расширенное условие $feasible(r_i, u) = 1$.

4) Оценка нутриентного соответствия

Каждый рецепт характеризуется энергетической ценностью и БЖУ: $E(r_i), P(r_i), F(r_i), C(r_i)$. Для количественной оценки соответствия вводится функция отклонения от целевого профиля:

$$\Delta(r_i, u) = w_E \left| \frac{E(r_i) - E_u}{E_u} \right| + w_P \left| \frac{P(r_i) - P_u}{P_u} \right| + w_F \left| \frac{F(r_i) - F_u}{F_u} \right| + w_C \left| \frac{C(r_i) - C_u}{C_u} \right|, \quad (16)$$

где $w_E, w_P, w_F, w_C \geq 0$ — веса критериев, задающие относительную важность калорийности и каждого макроэлемента. Чем меньше $\Delta(r_i, u)$, тем ближе рецепт к целевым значениям пользователя.

5) Итоговая функция ранжирования и построение рекомендаций

Для построения ранжированного списка используется объединённый скоринг, который учитывает семантическую релевантность и нутриентное соответствие:

$$S(r_i | q, u) = \alpha \cdot \text{sim}_{\cos}(q, x_i) - (1 - \alpha) \cdot \Delta(r_i, u), \quad \alpha \in [0, 1]. \quad (37)$$

Окончательный список рекомендаций формируется сортировкой допустимых кандидатов по убыванию S и выбором первых N элементов:

$$R(u) = \text{Top}N_{r_i \in F_K(q, u)} S(r_i | q, u). \quad (38)$$

Таким образом, алгоритм рекомендаций формализуется как задача ранжирования рецептов, в которой кандидатный набор формируется через векторный поиск (KNN по эмбедингам), затем применяется строгая фильтрация по аллергенам, после чего выполняется ранжирование по комбинированному критерию, учитывающему семантическую близость и близость нутриентных характеристик рецепта к индивидуальным нормам пользователя. Такая модель обеспечивает персонализацию рекомендаций, воспроизводимость вычислений и

возможность интерпретации результата через используемые компоненты целевой функции.

2.3. Исходные данные

В качестве исходных данных для проведения экспериментов в данной работе используются данные о рецептах и пищевой ценности блюд, представленные в открытом доступе. Рецепты рассматриваются как объекты рекомендаций и включают как неструктурированную (естественно-языковую) информацию — описание и инструкцию приготовления, так и структурированные признаки — ингредиентный состав, энергетическую ценность и показатели БЖУ. Подобное сочетание типов данных является принципиально важным для решаемой задачи: текстовые поля используются для семантического поиска и построения векторных представлений рецептов, тогда как нутриентные характеристики и ограничения пользователя применяются для фильтрации и ранжирования рекомендаций.

В качестве основных источников рецептов рассматриваются открытые наборы данных, публикуемые на платформах обмена датасетами (в частности, Kaggle), а также открытые кулинарные базы и агрегаторы рецептов, предоставляющие загрузки или структурированные представления блюд. Дополнительно, для повышения полноты и корректности нутриентных характеристик могут использоваться открытые справочники пищевой ценности продуктов (например, базы продуктов питания), применяемые для расчёта калорийности и БЖУ по ингредиентному составу.

На момент выполнения работы отсутствует единый открытый датасет, который одновременно удовлетворял бы всем требованиям задачи персонализированных рекомендаций по питанию: наличие текстов рецептов, корректных и сопоставимых показателей калорийности и БЖУ, а также явной

разметки по аллергенам и диетическим ограничениям. На практике открытые наборы данных часто содержат либо только текстовые поля (название, ингредиенты, инструкции), либо нутриенты в неполном виде, либо разнородные значения, заданные в разных единицах (на 100 г, на порцию, на весь рецепт). Кроме того, информация об аллергенах, как правило, не размечена напрямую и требует дополнительной обработки, поскольку аллергены являются производной характеристикой, определяемой по составу ингредиентов и их принадлежности к аллергенным группам (молоко, яйца, рыба, орехи, глютен и т. п.). В связи с этим в данной работе предполагается формирование собственного экспериментального набора данных путём объединения источников и предобработки.

Итоговый датасет имеет табличную структуру, где каждая строка соответствует одному рецепту r_i . Для каждого рецепта сохраняются следующие поля:

- уникальный идентификатор рецепта;
- название рецепта;
- текстовое описание и/или инструкция приготовления;
- список ингредиентов (в виде текста или нормализованного перечня);
- энергетическая ценность (калорийность);
- содержание белков, жиров и углеводов (БЖУ);
- бинарные признаки наличия аллергенов по фиксированному перечню аллергенных категорий.

$$(r_i, E_i, P_i, F_i, C_i, a_{i1}, a_{i2}, \dots, a_{iM}), \quad (39)$$

где r_i — совокупность текстовых полей рецепта (название, ингредиенты, инструкция), E_i — калорийность, P_i, F_i, C_i — значения белков, жиров и углеводов, а $a_{ij} \in \{0,1\}$ — индикатор наличия j -й аллергенной группы в рецепте (при M фиксированных группах аллергенов).

Таким образом, исходные данные обеспечивают возможность реализации гибридного подхода к рекомендациям: семантического поиска рецептов по текстовым признакам (через векторные представления) и строгой фильтрации по аллергенам и нутриентным ограничениям (через структурированные метаданные). Это позволяет проводить эксперименты по оценке релевантности рекомендаций и корректности выполнения пользовательских ограничений в рамках прототипа системы.

2.4. Программно-алгоритмическая архитектура решения

В качестве основного языка программирования для решения поставленной задачи выбран Python, что обусловлено его широким применением при разработке рекомендательных систем, обработке данных, интеграции моделей машинного обучения и построении прототипов веб-приложений. Архитектура решения предполагает модульное построение, включающее подсистемы подготовки данных, семантического поиска, фильтрации по ограничениям, нутриентного ранжирования и формирования объяснений рекомендаций.

В ходе реализации планируется использование следующих технологий и библиотек:

- Pandas, NumPy — для загрузки датасета рецептов, хранения данных в табличной форме, предобработки, нормализации единиц измерения, вычисления производных признаков (например, перевод нутриентов на порцию);
- re / regex — для базовой текстовой предобработки: очистки строк, нормализации ингредиентов, токенизации и упрощения текстовых полей, используемых при построении эмбедингов;
- SentenceTransformers / transformers (или API-клиент выбранной модели эмбедингов) — для построения векторных представлений рецептов и пользовательского запроса;

- Chroma DB — для хранения эмбедингов рецептов и выполнения семантического поиска (Top-K ближайших соседей) по метрике сходства;
- PostgreSQL (или структурированное локальное хранилище на этапе прототипа) — для хранения метаданных рецептов (КБЖУ, ингредиенты, аллергены, категории) и реализации строгой фильтрации и ранжирования;
- Streamlit — для разработки пользовательского интерфейса веб-приложения (ввод параметров пользователя, отображение рекомендаций и объяснений);
- OpenAI API или FLAN-T5 — для генерации текстовых объяснений рекомендаций на основе рассчитанных норм и характеристик выбранного рецепта;
- Matplotlib (опционально) — для визуализации результатов экспериментов (распределения калорийности, покрытие аллергенов, анализ качества выдачи).

К реализации планируется следующий алгоритм работы системы:

1. Загрузка и предобработка датасета рецептов: удаление некорректных записей, приведение форматов хранения ингредиентов и нутриентов к единому виду, заполнение пропусков, нормализация калорийности и БЖУ (при необходимости — пересчёт на порцию);
2. Формирование аллергенных метаданных: разметка рецептов по аллергенным группам на основе состава ингредиентов и/или доступных тегов;
3. Построение векторных представлений рецептов: преобразование текстовых полей (название, ингредиенты, описание/инструкция) в эмбединги и сохранение их во векторной базе данных Chroma DB;
4. Разработка пользовательского интерфейса: создание формы ввода параметров пользователя (антропометрия, цель, активность, аллергены, предпочтения) и элементов отображения результатов;

5. Расчёт персональных норм пользователя: вычисление БОВ по Харрису–Бенедикту, расчёт TDEE и целевых значений калорийности и БЖУ в зависимости от цели;
6. Семантический поиск кандидатов: построение вектора запроса пользователя и извлечение Top-K наиболее близких рецептов из Chroma DB по косинусному сходству (KNN/ANN);
7. Строгая фильтрация и ранжирование: исключение рецептов, содержащих аллергены и запрещённые ингредиенты, и сортировка оставшихся кандидатов по степени соответствия целевому профилю пользователя (калорийность и БЖУ);
8. Генерация объяснений рекомендаций: формирование структурированного контекста (цель, нормы, свойства рецепта) и получение текста объяснения с использованием LLM (OpenAI API или FLAN-T5);
9. Вывод результата пользователю: отображение итогового списка рекомендаций и объяснений в интерфейсе, а также (при необходимости) вывод диагностической информации для анализа качества системы.

Таким образом, программно-алгоритмическая архитектура решения обеспечивает полный цикл формирования персонализированных рекомендаций: от предобработки рецептов и построения эмбедингов до семантического поиска, строгой фильтрации по аллергенам, нутриентного ранжирования и генерации интерпретируемых текстовых объяснений.

ЗАКЛЮЧЕНИЕ

В рамках данной КНИР был проведён анализ предметной области персонализированного питания и рассмотрена проблематика построения рекомендательной системы, способной учитывать индивидуальные параметры пользователя. Показано, что широко распространённые приложения и сервисы, ориентированные на контроль питания и подсчёт калорий, в большинстве случаев предоставляют пользователю общие рекомендации и не обеспечивают комплексной персонализации с одновременным учётом целей (снижение массы тела, набор мышечной массы, поддержание формы), антропометрических характеристик, пищевых ограничений и необходимости прозрачного объяснения выдаваемых рекомендаций.

Также были изучены методы машинного обучения, применяемые в рекомендательных системах, включая контентно-ориентированные, коллаборативные и гибридные подходы, и обоснован выбор гибридной схемы как наиболее подходящей для задач питания, где существенную роль играют как смысловая релевантность рецепта запросу пользователя, так и строгие доменные ограничения. Сформулирована математическая постановка задачи, включающая расчет индивидуальных норм калорийности и БЖУ на основе антропометрических данных (в том числе с применением формулы Харриса–Бенедикта), формализацию фильтрации по аллергенам как системы жёстких ограничений и построение ранжирующей функции, объединяющей семантическую близость и нутриентное соответствие рецепта целевому профилю пользователя.

За время выполнения КНИР были приобретены практические компетенции по анализу литературы и аналогов, формализации содержательной и математической постановки задачи, проектированию алгоритма рекомендаций и архитектуры прототипа. Сформирована программно-алгоритмическая

архитектура решения на основе Python с использованием Streamlit для интерфейса, Chroma DB для хранения эмбеддингов и семантического поиска, а также языковой модели (через OpenAI API или FLAN-T5) для генерации объяснений рекомендаций.

В дальнейшем, в рамках выполнения выпускной квалификационной работы, планируется подбор и подготовка датасета рецептов с унифицированными нутриентными характеристиками и аллергенными метаданными, построение векторного индекса, реализация прототипа веб-приложения и проведение экспериментальных исследований для оценки качества рекомендаций по критериям релевантности, соблюдения ограничений и удобства интерпретации результатов. Таким образом, на данном этапе цель КНИР можно считать частично достигнутой, поскольку выполнены аналитическая и постановочная части исследования и сформирован фундамент для практической реализации и экспериментальной валидации системы в рамках ВКР.

СПИСОК ЛИТЕРАТУРЫ

1. Recommender Systems Handbook / ed. by F. Ricci, L. Rokach, B. Shapira. — 3rd ed. — Cham : Springer, 2022.
2. Aggarwal C. C. Recommender Systems: The Textbook. — Cham : Springer, 2016.
3. Baeza-Yates R., Ribeiro-Neto B. Modern Information Retrieval: The Concepts and Technology Behind Search. — 2nd ed. — Boston : Addison-Wesley, 2011.
4. James G., Witten D., Hastie T., Tibshirani R. An Introduction to Statistical Learning: with Applications in R. — 2nd ed. — New York : Springer, 2021.
5. Géron A. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. — 3rd ed. — Sebastopol, CA : O'Reilly Media, 2022.
6. Burkov A. The Hundred-Page Machine Learning Book. — [Б. м.] : Andriy Burkov, 2019.
7. Jurafsky D., Martin J. H. Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models. — 3rd ed. — Online manuscript released January 6, 2026. — [Электронный ресурс]. — URL: <https://web.stanford.edu/~jurafsky/slp3/> (дата обращения: 14.01.2026).
8. Tunstall L., von Werra L., Wolf T. Natural Language Processing with Transformers. — Revised ed. — Sebastopol, CA : O'Reilly Media, 2022.
9. Molnar C. Interpretable Machine Learning: A Guide for Making Black Box Models Explainable. — 2nd ed. — [Электронный ресурс]. — URL: <https://christophm.github.io/interpretable-ml-book/> (дата обращения: 14.01.2026).
10. МР 2.3.1.2432—08. Нормы физиологических потребностей в энергии и пищевых веществах для различных групп населения Российской Федерации :

метод. рекомендации : утв. 18.12.2008. — [Электронный ресурс]. — URL: https://rospotrebnadzor.ru/documents/details.php?ELEMENT_ID=4583 (дата обращения: 14.01.2026).

11. Нутрициология и клиническая диетология : национальное руководство / под ред. В. А. Тутельяна, Д. Б. Никитюка. — М. : ГЭОТАР-Медиа, 2020. — 656 с.

12. Energy and Protein Requirements: Report of a Joint FAO/WHO/UNU Expert Consultation. — Geneva : World Health Organization, 1985. — (WHO Technical Report Series ; 724).

13. Sports Nutrition: A Handbook for Professionals / Academy of Nutrition and Dietetics ; ed. by C. Karpinski, C. Rosenbloom. — 6th ed. — Chicago, IL : Academy of Nutrition and Dietetics, 2017.

14. Озерова Е. Приложения для подсчёта калорий в 2025 году: топ-6 [Электронный ресурс] // Skillbox Media. — 23.12.2024. — URL: <https://skillbox.ru/media/health/calorie-counter-apps/> (дата обращения: 14.01.2026).

15. 10 лучших приложений с рецептами ПП (правильного питания) [Электронный ресурс] // Национальный центр здорового питания (NutriSteppe). — [Б. г.]. — URL: <https://ncn.nutristeppe.com/blog/10-luchshih-prilozhenij-s-receptami-pp-pravilnogo-pitaniya> (дата обращения: 14.01.2026).

16. akimovpro. Раскрывая секреты LLM: руководство по основным понятиям больших языковых моделей без хайпа [Электронный ресурс] // Хабр. — 14.12.2023. — URL: <https://habr.com/ru/articles/768844/> (дата обращения: 14.01.2026).

17. Телегин И. Ликбез по AI: Какие бывают LLM (GPT, BERT, T5) и какую нейросеть выбрать для вашей задачи? [Электронный ресурс] // vc.ru. — 17.07.2025. — URL: <https://vc.ru/ai/2105576-likbez-po-ai-kak-vybrat-llm-dlya-zadach> (дата обращения: 14.01.2026).